

Exploratory Data Analysis

Fundamentos y Formalizaciones

Pastor E. Pérez Estigarribia
Facultad de Ingeniería y Arquitectura
Escuela de Posgrado
Universidad de El Salvador

2026

Objetivos de la sesión

- **Contextualizar** históricamente el surgimiento del EDA.
- **Identificar** los conceptos fundamentales y su rol en la práctica.
- **Formalizar** las ideas clave con notación matemática mínima.
- **Definir** la nomenclatura y funciones relevantes para la clase práctica posterior.

Nota: el EDA es un estado mental iterativo, no un protocolo rígido.

Origen y motivación

- Década de 1970: reacción contra enfoques excesivamente modelocéntricos.
- John W. Tukey promovió la observación gráfica y la exploración antes de la confirmación.
- EDA como herramienta para generar preguntas y diseñar análisis posteriores.

*Nota: es importante diferenciar entre **descubrir** y **confirmar**.*

Consecuencias prácticas

- Mayor énfasis en visualización y en la inspección de residuos.
- Desarrollo de herramientas interactivas y lenguajes ($S \rightarrow R$, tidyverse).
- Cooperación entre EDA y análisis confirmatorio en ciclos de investigación.

Nota: p. ej., detectar outliers que cambian la interpretación de una prueba.

¿Qué es EDA?

- Un proceso iterativo para **visualizar**, **resumir** y **detectar** problemas en los datos.
- No es confirmatorio: su objetivo es *formular* hipótesis y preparar análisis posteriores.

Nota: El EDA reduce las sorpresas y guía el diseño de experimentos.

Ciclo de trabajo en EDA

- 1 **Visualizar** para obtener intuición.
- 2 **Transformar** (limpieza, creación de variables).
- 3 **Modelar** de forma exploratoria (ajustes simples).
- 4 **Revisar** y refinar preguntas.

- **Data = fit + residuals.**
- **Willingness to notice:** estar dispuesto a notar fenómenos azarosos y persistentes.
- **Stripping layers:** quitar capas descriptivas para revelar estructura.
- **Ver antes de confirmar:** gráficos y tablas bien planificados.

Nomenclatura: símbolos y términos

Símbolo / término	Definición breve
y	Variable respuesta observada.
x	Predictor(s) o variable(s) explicativa(s).
$\hat{f}(x)$	Ajuste estimado (modelo exploratorio).
ε	Residuo o ruido.
$K(\cdot)$	Núcleo (kernel) en estimación de densidad.
h	Bandwidth / binwidth (suavizado).

Definiciones de funciones estadísticas (breves)

- **Media:** $\bar{x} = \frac{1}{n} \sum x_i$. Medida de tendencia central sensible a outliers.
- **Mediana:** valor central; robusta frente a outliers.
- **IQR:** rango intercuartílico = $Q_3 - Q_1$; usado en boxplots para detectar outliers.
- **Kernel density:** suaviza la distribución empírica; alternativa al histograma.

Formalización: descomposición señal-ruido

$$y = f(x) + \varepsilon$$

- y : variable respuesta observada.
- $f(x)$: patrón o señal (puede ser no paramétrico o paramétrico).
- ε : residuo, ruido o variación no explicada.

Nota: en EDA $\hat{f}$ se usa para extraer la señal y estudiar ε .

$$r_i = y_i - \hat{f}(x_i)$$

- Visualizar r_i vs $\hat{f}(x_i)$ para detectar heterocedasticidad y no linealidad.
- Histogramas y QQ-plots de residuos para evaluar simetría y colas.

Formalización: estimación empírica de densidad

$$\hat{f}(x) \approx \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

- K : núcleo (kernel) — función de suavizado.
- h : ancho de banda (bandwidth) — controla suavidad; análogo a binwidth.
- En histogramas, h corresponde al ancho del bin.

Nota: Un h demasiado grande oculta estructura; demasiado pequeño muestra ruido.

Formalización: distribuciones conjuntas y condicionales

$$f_{X,Y}(x, y), \quad f_{Y|X}(y | x)$$

- $f_{X,Y}$: describe la densidad conjunta; útil para scatterplots y binning 2D.
- $f_{Y|X}$: distribución condicional; justifica boxplots condicionados y discretización.

Nota: funciones en R: `geom_hex`, `cut_width`, `cut_number`.

Visuales esenciales, interpretación y criterios: histograma, boxplot, scatter, hex/bin2d, heatmap

- Histograma
- Boxplot (diagrama de caja)
- Scatterplot (diagrama de dispersión)
- Hex / bin2d (agrupamiento 2D)
- Heatmap / geom_tile (mapa de calor de contingencia)
- Resumen y recomendaciones prácticas

Nota: cada visual incluye criterios de interpretación, señales de alarma y ejemplos conceptuales.

Histograma: propósito y uso

Propósito: visualizar la distribución empírica de una variable continua; identificar moda(s), asimetría y colas. **Cuándo usarlo:**

- Explorar la variación de una sola variable continua.
- Detectar multimodalidad y valores atípicos visibles.

Nota: útil como primer paso para entender la forma de la distribución.

Histograma: criterios de interpretación

- **Moda(s):** ¿hay uno o varios picos? Multimodalidad sugiere subpoblaciones.
- **Asimetría:** cola larga a la derecha (sesgo positivo) o a la izquierda (sesgo negativo).
- **Colas y outliers:** barras aisladas en extremos indican valores raros.
- **Efecto del binwidth:** binwidth grande suaviza y puede ocultar picos; binwidth pequeño muestra ruido.
- **Comparaciones:** superponer densidades o usar facetas para comparar subgrupos.

Nota: siempre explorar varios valores de binwidth y complementar con densidad kernel.

Histograma: señales de alarma y acciones

- **Picos inesperados en valores redondeados:** posible efecto humano (medición o agrupamiento).
- **Barras en 0 o valores imposibles:** revisar calidad de captura; considerar NA o corrección.
- **Distribución muy sesgada:** considerar transformaciones (log, sqrt) para análisis posteriores.
- **Si hay multimodalidad:** investigar subgrupos, variables categóricas relacionadas o mezcla de poblaciones.

Nota: documentar decisiones de limpieza y transformación en un cuaderno o flujo reproducible.

Boxplot: propósito y uso

Propósito: resumir la distribución condicional de una variable continua por niveles de una categórica; mostrar mediana, IQR y outliers. **Cuándo usarlo:**

- Comparar distribuciones entre grupos.
- Detectar diferencias en mediana y dispersión.

Nota: los boxplots son robustos y compactos; complementarlos con jitter o violin plots si la muestra es pequeña.

Boxplot: criterios de interpretación

- **Mediana:** posición central; comparar entre grupos.
- **IQR ($Q3-Q1$):** dispersión central; grupos con IQR mayor son más variables.
- **Whiskers y outliers:** puntos fuera de 1.5 IQR se marcan como atípicos; investigar su origen.
- **Simetría dentro de la caja:** caja desplazada indica sesgo dentro del grupo.
- **Número de observaciones:** boxplot no muestra tamaño de muestra; añadir conteos o usar boxplots escalados por n .

Nota: cuando hay muchos outliers, mostrar también la distribución completa (violin o densidad).

Boxplot: señales de alarma y acciones

- **Outliers sistemáticos en un grupo:** revisar proceso de medición o subpoblación distinta.
- **Grupos con IQR muy distinto:** considerar heterocedasticidad para análisis posteriores.
- **Cajas vacías o con pocos datos:** evitar conclusiones; mostrar conteos.
- **Si la variable continua fue discretizada:** verificar que la discretización no oculte patrones.

Nota: reportar cómo se definieron los grupos y el criterio para marcar outliers.

Scatterplot: propósito y uso

Propósito: visualizar la relación entre dos variables continuas; detectar correlación, no linealidad y patrones locales. **Cuándo usarlo:**

- Explorar covariación continua vs continua.
- Evaluar la forma de la relación (lineal, curvilínea, heterocedástica).

Nota: añadir color o tamaño para una tercera variable categórica o continua; usar smoothing para ver tendencia.

Scatterplot: criterios de interpretación

- **Dirección:** positiva, negativa o nula.
- **Fuerza:** dispersión alrededor de la tendencia; puntos muy dispersos indican baja correlación.
- **Forma:** lineal, curvilínea, umbral, cúmulos.
- **Heterocedasticidad:** variabilidad de Y cambia con X ; importante para modelado.
- **Outliers y leverage points:** puntos extremos en X o Y que pueden influir en ajustes.

Nota: complementar con ajuste local (loess) y con visualización de residuos tras ajustar un modelo simple.

Scatterplot: señales de alarma y acciones

- **Overplotting (muchos puntos superpuestos):** usar alpha, jitter, binning 2D o `geom_hex`.
- **Puntos con alto leverage:** evaluar su influencia en modelos; considerar robust regression o análisis con/sin ellos.
- **Patrones no lineales:** considerar transformaciones o modelos no lineales.
- **Clusters visibles:** investigar subgrupos o variables latentes.

Nota: documentar cualquier punto removido o tratado y justificar la decisión.

Propósito: resolver overplotting en scatterplots grandes mediante agregación espacial; mostrar densidad conjunta. **Cuándo usarlo:**

- Con datasets muy grandes donde los puntos se superponen.
- Para visualizar la estructura de densidad en el plano (X,Y).

Nota: elegir número de bins/hexágonos según resolución y densidad de datos.

- **Patrones de densidad:** zonas oscuras/coloreadas indican mayor concentración de observaciones.
- **Gradientes y límites:** detectar regiones con cambios bruscos en densidad.
- **Elección de bins:** bins muy grandes ocultan estructura; muy pequeños muestran ruido.
- **Comparaciones entre subgrupos:** usar facetas o normalizar por total para comparar densidades relativas.

Nota: acompañar con una leyenda clara y, si procede, con contornos de densidad (stat_density2d).

Hex / bin2d: señales de alarma y acciones

- **Zonas vacías inesperadas:** revisar filtros o problemas de muestreo.
- **Efecto de escala:** transformar ejes si la relación es multiplicativa.
- **Si se requiere precisión en conteos:** calcular tablas agregadas y mostrar números además del color.

Nota: documentar la elección de bins y justificarla en el reporte.

Propósito: visualizar tablas de contingencia o agregados bidimensionales mediante color; útil para dos categóricas o una categórica + discretizada continua. **Cuándo usarlo:**

- Explorar dependencia entre dos variables categóricas.
- Mostrar conteos, proporciones o estadísticas agregadas (media, mediana).

Nota: normalizar por filas/columnas si interesa proporción en lugar de conteo absoluto.

Heatmap: criterios de interpretación

- **Patrones de color:** zonas intensas indican combinaciones frecuentes o valores agregados altos.
- **Escala de color:** elegir paleta perceptualmente uniforme; indicar si la escala es absoluta o relativa.
- **Ordenamiento:** reordenar filas/columnas puede revelar estructura (seriation).
- **Anotaciones:** mostrar números en celdas cuando sea necesario para precisión.

Nota: evitar paletas que confundan (p. ej., arcoíris); preferir viridis o similares).

Heatmap: señales de alarma y acciones

- **Celdas con conteos muy bajos:** considerar agrupar categorías raras o mostrar proporciones.
- **Patrones espurios por ordenamiento:** probar distintos ordenamientos y justificar el elegido.
- **Si la matriz es muy dispersa:** usar `geom_count` o puntos escalados en lugar de tiles.

Nota: documentar si se normalizó por fila, columna o total y por qué.

Resumen: buenas prácticas al usar visuales

- **Combinar visuales:** un histograma + boxplot + scatter ofrece una visión más completa.
- **Explorar parámetros:** probar varios binwidths, bins y transformaciones.
- **Documentar decisiones:** registrar filtros, transformaciones y criterios de limpieza.
- **Priorizar claridad:** leyendas, etiquetas y escalas claras; evitar paletas engañosas.
- **Reproducibilidad:** todo análisis visual debe poder regenerarse desde el cuaderno.

Funciones en R (ggplot2 / tidyverse)

- `geom_histogram()`: construye histogramas; controla binwidth.
- `geom_boxplot()`: resume distribución condicional (mediana, IQR, outliers).
- `geom_point()`: scatterplot; útil para covariación continua vs continua.
- `geom_hex()` / `geom_bin2d()`: 2D binning para evitar overplotting.
- `geom_tile()`: heatmap a partir de tabla de contingencia.
- `cut_width(x,w)` / `cut_number(x,n)`: discretización de continuas para boxplots condicionados.

Nota: intuición detrás de las geometrias en R.

Funciones y transformaciones comunes

- **filter()**: seleccionar subconjuntos por condición lógica.
- **mutate()**: crear o transformar variables.
- **group_by() + summarise()**: agregación por grupos (medias, medianas, conteos).
- **add_residuals()** / **add_predictions()**: añadir columnas con residuos/predicciones para diagnóstico.

- Lectura recomendada: *R for Data Science* (capítulos EDA y Model).
- Lectura fundacional: John W. Tukey, *Exploratory Data Analysis* (fragmentos).
- Próximo paso: diapositivas detalladas de visuales + práctico en Colab.