

Inferencia Estadística

Conceptos y Formulación Básica (3.1–3.6)

Pastor E Pérez Estigarribia — Curso de Inferencia

2 de junio de 2026

- 3.1 Distribución muestral
- 3.2 Estadística bayesiana
- 3.3 Método Bayesiano (pasos prácticos)
- 3.4 Redes Bayesianas (DAGs y inferencia)
- 3.5 Estimación en muestras grandes (propiedades asintóticas)
- 3.6 Prueba de hipótesis (frecuentista y permutación)

3.1 Distribución muestral — Definición

- **Distribución muestral:** la distribución de un estadístico (p. ej. $\bar{X}$, mediana, proporción) cuando repetimos el muestreo bajo el mismo procedimiento.
- **Objetivo:** cuantificar la variabilidad del estimador y construir intervalos de incertidumbre y pruebas.
- **Notación:** si $X_1, \dots, X_n$ i.i.d. (independientes e idénticamente distribuidas) con media μ y varianza σ^2 , la media muestral es

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Teorema del Límite Central (CLT)

- **Enunciado:** para X_i i.i.d. con media μ y varianza finita σ^2 ,

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1) \quad (n \rightarrow \infty).$$

- **Consecuencia práctica:** para n suficientemente grande,

$$\bar{X} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

- **Uso:** aproximaciones para intervalos y pruebas aun cuando la población no sea normal.

- **Error estándar de la media:**

$$\text{se}(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

- **Intervalo de confianza aproximado (nivel $1 - \alpha$):**

$$\bar{X} \pm z_{1-\alpha/2} \text{se}(\bar{X}).$$

- **Cuando σ es desconocida:** usar $\hat{\sigma}$ y la distribución t para muestras pequeñas.

Ejemplo y actividad (Colab)

- Simular 10 000 medias muestrales de una distribución exponencial para $n = 5, 30, 100$.
- Visualizar histogramas y superponer la densidad normal teórica.
- Objetivo: observar la convergencia hacia la normalidad y el efecto del tamaño muestral.

3.2 Estadística bayesiana — Idea central

- **Parámetros como variables aleatorias:** la incertidumbre sobre θ se expresa con una distribución.
- **Regla de Bayes:**

$$p(\theta \mid y) = \frac{p(y \mid \theta) p(\theta)}{p(y)} \propto p(y \mid \theta) p(\theta).$$

- **Interpretación:** el *posterior* combina la información previa (prior) con la evidencia (likelihood).

Prior, verosimilitud y posterior

- **Prior** $p(\theta)$: refleja creencias antes de ver datos.
- **Likelihood** $p(y \mid \theta)$: modelo de los datos dado θ .
- **Posterior** $p(\theta \mid y)$: creencia actualizada.
- **Marginal de los datos**: $p(y) = \int p(y \mid \theta)p(\theta) d\theta$.

- **Intervalo creíble:** intervalo que contiene una fracción $1 - \alpha$ de la masa posterior.
- **Diferencia con frecuentista:** el intervalo creíble es probabilístico sobre θ ; el intervalo de confianza es sobre el procedimiento.
- **Sensibilidad al prior:** evaluar con priors alternativos y priors no informativos.

Ejemplo conjugado: Beta–Binomial

- Datos: $y \sim \text{Binomial}(n, \theta)$.
- Prior: $\theta \sim \text{Beta}(\alpha, \beta)$.
- Posterior: $\theta \mid y \sim \text{Beta}(\alpha + y, \beta + n - y)$.
- **Cálculo directo:** media posterior $\frac{\alpha + y}{\alpha + \beta + n}$.


3.3 Método Bayesiano — Pasos

- 1 **Modelar** la verosimilitud $p(y \mid \theta)$.
- 2 **Elegir** un prior $p(\theta)$.
- 3 **Calcular** el posterior $p(\theta \mid y)$.
- 4 **Inferir** (estimadores, intervalos creíbles, predicción).
- 5 **Comprobar** ajuste y sensibilidad.

- **MCMC:** Metropolis–Hastings, Gibbs sampling para posteriors complejos.
- **Variational Inference:** aproximaciones determinísticas.
- **Conjugados:** cuando existen soluciones analíticas (rápido y exacto).
- **Predictiva posterior:**

$$p(\tilde{y} | y) = \int p(\tilde{y} | \theta) p(\theta | y) d\theta.$$

Caso de estudio, modelado de COVID-19¹



¹ Appl. Sci. 2021, 11(20), 9726; <https://doi.org/10.3390/app11209726>

SEIR-H

$$\frac{dS}{dt} = -\beta \frac{S}{N} I, \quad (1)$$

$$\frac{dE}{dt} = \beta \frac{S}{N} I - \alpha E, \quad (2)$$

$$\frac{dI}{dt} = \alpha E - \gamma I, \quad (3)$$

$$\frac{dR}{dt} = \gamma I + R_{im}. \quad (4)$$

Las ecuaciones (1), (2), (3) y (4), respectivamente, muestran la dinámica de los compartimentos de: el susceptible S , el E expuesto, el I infeccioso y el R reportado. El término R_{im} representa una tasa de casos reportados como viajeros, lo cual fue relevante al inicio de la dinámica del COVID-19 en Paraguay.

SEIR-H

$$\frac{dH}{dt} = \lambda_{I \rightarrow H} \gamma I - \lambda_{H \rightarrow U} \delta_{H \rightarrow U} H - \lambda_{H \rightarrow F} \delta_{H \rightarrow F} H - \lambda_{H \rightarrow O} \delta_{H \rightarrow O} H, \quad (5)$$

$$\frac{dU}{dt} = \lambda_{H \rightarrow U} \delta_{H \rightarrow U} H - \lambda_{U \rightarrow F} \varphi_{U \rightarrow F} U - \lambda_{U \rightarrow O} \varphi_{U \rightarrow O} U, \quad (6)$$

$$\frac{dF}{dt} = \lambda_{I \rightarrow F} \gamma I + \lambda_{H \rightarrow F} \delta_{H \rightarrow F} H + \lambda_{U \rightarrow F} \varphi_{U \rightarrow F} U. \quad (7)$$

Dados los $A, B = \{I, O, H, U, F\}$ estados posibles, la dinámica de la proporción de individuos infectados con un desenlace $A \rightarrow B$ se representa mediante el uso de un parámetro $\lambda_{A \rightarrow B}$. La duración promedio de la estadía en un estado A antes de pasar a B está dada por $1/\delta_{A \rightarrow B}$.

Estimación de los parámetros del modelo dado los datos

Los datos disponibles son registros diarios de:

- 1 diagnosticado con casos confirmados positivos o casos reportados diariamente $D^R(t_j)$
- 2 diagnosticado con casos positivos confirmados en los grupos aislados que eran viajeros del exterior $R_{im}(t_j)$,
- 3 ocupación de sala en los hospitales por los pacientes de COVID-19 $D^H(t_j)$,
- 4 ocupación en UCI por pacientes de COVID-19 $D^U(t_j)$,
- 5 muertes diarias confirmadas por COVID-19 $D^F(t_j)$.

Algoritmo de estimación de parámetros²

Algorithm 1: Parameter estimation

Input: $t_0, j_h, j_{\text{end}}, N, \alpha, \gamma, \delta, \varphi, W,$
 $\{D^R(t_j), D^H(t_j), D^U(t_j), D^F(t_j), R_{im}(t_j) | 1 \leq j \leq j_{\text{end}}\}$
Result: $\{\beta(t_j) | 0 \leq j \leq j_{\text{end}} - W\}, \{\lambda_*(t_j) | j_h \leq j \leq j_{\text{end}} - W\}$

```
1 at  $t_0$ , estimate the values  $E(t_0), I(t_0), \beta(t_0)$  using (10); // See Section 2.3.1
2 for  $j = 1; j \leq j_{\text{end}} - W; j = j + 1$  do
3   estimate  $\beta(t_j)$  using (16); // See Section 2.3.2
4   if  $j \geq j_h$  then
5     estimate  $\lambda_*(t_j)$  using (19); // See Section 2.3.3
6   end
7 end
```

El algoritmo muestra esquemáticamente el procedimiento para la estimación de parámetros. La información requerida es el conjunto de parámetros que se mantienen constantes, los datos $D^R(t_j), D^H(t_j), D^U(t_j), D^F(t_j), R_{im}(t_j)$, desde $j = 1$ a $j = j_{\text{end}}$, la población N y tamaño de la ventana de tiempo W . Los resultados son la transmisibilidad $\beta(t_j)$ de $j = 0$ a $j = j_{\text{end}} - W$, y las proporciones $\lambda_*(t_j)$ de $j = j_h$ a $j = j_{\text{end}} - W$.

²Appl. Sci. 2021, 11(20), 9726; <https://doi.org/10.3390/app11209726>

Estimación de la distribución a posteriori de parámetros³

Estimación en un marco bayesiano:

- 1 Condición inicial: $P(e_0, i_0, \beta_0, \sigma_0^R | D_0^R) \propto P(D_0^R | e_0, i_0, \beta_0, \sigma_0^R) P(e_0, i_0, \beta_0, \sigma_0^R)$,

$$P(D_0^R | e_0, i_0, \beta_0, \sigma_0^R) = \prod_{k=1}^W \frac{1}{\sqrt{2\pi}\sigma_0^R} \exp \left[-\frac{\left(D^R(t_0 + k) - dR^{e_0, i_0, \beta_0}(t_k) \right)^2}{2(\sigma_0^R)^2} \right].$$

- 2 Transmisibilidad: $P(\beta_j, \sigma_j^R | D_j^R) \propto P(D_j^R | \beta_j, \sigma_j^R) P(\beta_j, \sigma_j^R)$,

$$P(D_j^R | \beta_j, \sigma_j^R) = \prod_{k=1}^W \frac{1}{\sqrt{2\pi}\sigma_j^R} \exp \left[-\frac{\left(D^R(t_j + k) - dR^{\beta_j}(t_k) \right)^2}{2(\sigma_j^R)^2} \right].$$

- 3 Proporción de hosp., UCI y Fallecidos:

$$P(\lambda_{*j}, \sigma_j^H, \sigma_j^U, \sigma_j^F | D_j^H, D_j^U, D_j^F) \propto P(D_j^H, D_j^U, D_j^F | \lambda_{*j}, \sigma_j^H, \sigma_j^U, \sigma_j^F) P(\lambda_{*j}, \sigma_j^H, \sigma_j^U, \sigma_j^F)$$

$$P(D_j^\Gamma | \lambda_{*j}, \sigma_j^\Gamma) = \prod_{k=1}^W \frac{1}{\sqrt{2\pi}\sigma_j^\Gamma} \exp \left[-\frac{\left(D^\Gamma(t_j + k) - \Gamma^{\lambda_{*j}}(t_k) \right)^2}{2(\sigma_j^\Gamma)^2} \right], \quad \Gamma = H, U, F$$

³ In the estimation, stan uses the Hamiltonian Monte Carlo (HCM) algorithm of Markov chain Monte Carlo method (MCMC)

Parameter	Search Range	Prior Distribution
$E(t_0)$	[0, 100]	Uniform
$I(t_0)$	[0, 100]	Uniform
β	[0, 0,8]	Uniform
$\lambda_{I \rightarrow H}$	[0, 0,15]	Uniform
$\lambda_{I \rightarrow F}$	[0, 0,004]	Uniform
$\lambda_{H \rightarrow U}$	[0, 0,3]	Uniform
$\lambda_{H \rightarrow F}$	[0, 0,25]	Uniform
$\lambda_{U \rightarrow F}$	[0,2, 1]	Normal: $\mu = 0,4$, $\sigma = 0,1$

⁴ Appl. Sci. 2021, 11(20), 9726; <https://doi.org/10.3390/app11209726>

Transmisibilidad




Figura: La transmisibilidad estimada β^{opt} con intervalo de credibilidad del 95 %, obtenida con los datos de Paraguay. La línea horizontal en $1/7$ corresponde al valor de β que da el número de reproducción efectivo igual a uno.

Parámetros estimados de recursos hospitalarios




Figura: Proporciones para la dinámica en los hospitales: los valores óptimos con el intervalo de credibilidad 95 %.

Simulación vs datos




Figura: Las trayectorias de las simulaciones usando $\beta^{\text{opt}}(t)$ y $\lambda^{\text{opt}}(t)$ en comparación con los datos. Utilizando la distribución posterior estimada el 1 de abril de 2021, las regiones para las trayectorias se muestran con un mes de anticipación con intervalos de credibilidad del percentil 95.




Figura: Comparación del desempeño estadístico de la predicción de muertes diarias entre el modelo SEIR-H con las proyecciones IHME COVID-19. Los valores en los ejes de coordenadas se escalan con el score z (definido como: $[\phi - \text{ave}(\phi)] / \text{std}(\phi)$); las líneas continuas representan el ajuste a la ecuación lineal con intersección cero y pendiente estimada; las líneas punteadas muestran la ecuación lineal para la hipótesis del intercepto cero y la

Error de proyección





Figura: Comportamiento estadístico del error en función del horizonte de proyección.



⁵<http://epymodel.uaa.edu.py/>

Caso de estudio Epidemia de Chikungunya en Paraguay 2023

- **Objetivo:** estimar parámetros dinámicos y de observación del brote (p. ej. β_t , probabilidad de detección ρ , sobre-dispersión) usando un enfoque bayesiano.
- **Modelo base:** sistema compartimental SIR con compartimentos vacunados (S, V, I, IV, R, RV) — SIRV.
- **Datos disponibles:** series temporales de casos semanales $c_{\text{obs}}(t)$ y resultados de seroprevalencia $n_{\text{pos}}(t) / n_{\text{tot}}(t)$.

Sistema SIRV (forma general)

$$\begin{aligned}\frac{dS}{dt} &= -\beta_t \frac{S}{N} (I + I_V) - v(t)S, \\ \frac{dV}{dt} &= v(t)S - \beta_t(1 - \text{VE}_{\text{inf}}) \frac{V}{N} (I + I_V), \\ \frac{dI}{dt} &= \beta_t \frac{S}{N} (I + I_V) - \gamma I, \\ \frac{dI_V}{dt} &= \beta_t(1 - \text{VE}_{\text{inf}}) \frac{V}{N} (I + I_V) - \gamma I_V, \\ \frac{dR}{dt} &= \gamma I, \\ \frac{dR_V}{dt} &= \gamma I_V.\end{aligned}$$

$$N = S + V + I + I_V + R + R_V$$

Aquí β_t es la tasa de transmisión en la semana t , γ es la tasa de recuperación (1/duración infecciosa), $v(t)$ la tasa de vacunación por tiempo, y VE_{inf} la eficacia contra infección (si aplica).

Modelo de observación para casos (likelihood)

- Sea $i_{\text{exp}}(t)$ el número de nuevas infecciones esperadas en la semana t según el modelo (incidencia modelada).
- El número observado de casos $c_{\text{obs}}(t)$ se modela con una distribución **Negativa Binomial** para capturar sobredispersión y sub-detección:

$$c_{\text{obs}}(t) \sim \text{NegBin}(\mu = \rho i_{\text{exp}}(t), \kappa),$$

donde ρ es la probabilidad de detección y κ el parámetro de sobredispersión.

Modelo de observación para seroprevalencia

- Sea $s(t)$ la proporción susceptible en la población en la semana t (según el modelo).
- En la encuesta de seroprevalencia, $n_{\text{pos}}(t)$ positivos de $n_{\text{tot}}(t)$ se modelan como:

$$n_{\text{pos}}(t) \sim \text{Binomial}(n_{\text{tot}}(t), 1 - s(t)).$$

- Esta observación ancla la estimación de la inmunidad acumulada y mejora la identificación de la fuerza de transmisión.

- **Dinámicos:** $\{\beta_t\}_{t=1}^T$ (serie temporal de transmisión) o parametrización reducida (p. ej. splines, cambios por bloques).
- **Epidemiológicos:** γ (si no fijo), duración infecciosa $1/\gamma$.
- **Observación:** ρ (detección), κ (sobredispersión).
- **Vacunación/eficacia:** VE_{dis} (eficacia contra enfermedad), VE_{inf} (eficacia contra infección) si se modelan.
- **Condiciones iniciales:** $I(0)$, $I_V(0)$ o fracciones iniciales.

Elección de priors (ejemplos)

- β_t : prior log-normal o random-walk en escala log para suavizar la serie

$$\log \beta_t \sim \mathcal{N}(\log \beta_{t-1}, \sigma_\beta^2)$$

con $\log \beta_1 \sim \mathcal{N}(\mu_\beta, \tau_\beta^2)$.

- ρ (detección): $\rho \sim \text{Beta}(a_\rho, b_\rho)$ (p. ej. $\text{Beta}(2,50)$ si se espera baja detección).
- κ (sobredispersión): $\kappa \sim \text{Gamma}(a_\kappa, b_\kappa)$.
- VE: $\text{VE} \sim \text{Beta}(\alpha_{\text{VE}}, \beta_{\text{VE}})$ o fija según evidencia clínica.
- Condiciones iniciales: priors débiles normales/truncadas sobre fracciones positivas.

Posterior (forma general)

$$p(\Theta \mid \text{datos}) \propto p(\text{datos} \mid \Theta) p(\Theta),$$

donde Θ agrupa todos los parámetros y estados iniciales, y

$$p(\text{datos} \mid \Theta) = \prod_{t=1}^T p(c_{\text{obs}}(t) \mid i_{\text{exp}}(t; \Theta)) \times \prod_{t \in \mathcal{S}} p(n_{\text{pos}}(t) \mid s(t; \Theta)).$$

$$p(\Theta) = p(\{\beta_t\}) p(\rho) p(\kappa) p(\text{VE}) p(\text{ICs}) \dots$$

- **Algoritmos:** MCMC (Metropolis–Hastings, HMC/No-U-Turn en Stan/NumPyro), SMC, o métodos variacionales.
- **Pasos prácticos:**
 - 1 Integrar ODEs para cada propuesta de Θ (o usar aproximaciones rápidas).
 - 2 Evaluar likelihood y prior, calcular ratio de aceptación.
 - 3 Ejecutar cadenas múltiples, comprobar convergencia (R-hat, ESS), revisar trazas.
- **Costo:** integración ODE + MCMC es costoso; usar parametrizaciones parsimoniosas para β_t .

3.4 Redes Bayesianas — Concepto

- **Definición:** grafo acíclico dirigido (DAG) que representa dependencias condicionales entre variables.
- **Factorización:** si nodos $X_1, \dots, X_p$,

$$p(X_1, \dots, X_p) = \prod_{i=1}^p p(X_i \mid \text{Pa}(X_i)).$$

- $\text{Pa}(X_i)$ son los padres de X_i en el DAG.

¿Qué es una red bayesiana?

- **Definición:** modelo gráfico probabilístico representado por un DAG (grafo acíclico dirigido).
- **Nodos:** variables (observables, latentes o parámetros).
- **Aristas:** dependencias condicionales directas entre variables.

Factorización de la distribución conjunta

$$p(X_1, \dots, X_p) = \prod_{i=1}^p p(X_i \mid \text{Pa}(X_i))$$

- $\text{Pa}(X_i)$ son los padres de X_i en el DAG.
- **Consecuencia:** reduce la complejidad de especificar la distribución conjunta.

- Si no existe camino entre X y Y dado Z , entonces $X \perp Y \mid Z$.
- **D-separación:** criterio gráfico para leer independencias condicionales.

Tablas de probabilidad condicional (CPT)

- Cada nodo tiene una función $p(X_i \mid \text{Pa}(X_i))$.
- Para variables discretas: **CPT** con una fila por combinación de padres.
- Para continuas: usar distribuciones paramétricas (Gaussiana condicional, regresión).


- **Inferencia:** calcular $p(Q \mid E)$ (consulta Q dado evidencia E) — exacta (elimination, junction tree) o aproximada (MCMC, belief propagation).
- **Aprendizaje:** estimar estructura y/o parámetros desde datos (máxima verosimilitud, Bayesiano, score-based).

- **Aplicaciones:** diagnóstico médico, detección de fallos, genética, toma de decisiones.
- **Limitaciones:** requiere conocimiento/ datos para CPTs; estructura mal especificada induce sesgos.

Ejemplo didáctico (sprinkler)

- Supongamos que hay dos eventos los cuales pueden causar que la hierba esté húmeda: que el rociador esté activado o que esté lloviendo.
- También supongamos que la lluvia tiene un efecto directo sobre el uso del rociador (usualmente cuando llueve el rociador se encuentra apagado).
- Entonces la situación puede ser modelada con una red Bayesiana (como hemos visto).
- Las tres variables tienen dos posibles valores, T (para verdadero) y F (para falso).

LLUVIA	ROCIADOR	
	T	F
F	0.4	0.6
T	0.01	0.99



	LLUVIA	
	T	F
	0.2	0.8

		HIERBA HÚMEDA	
ROCIADOR	LLUVIA	T	F
F	F	0	1
F	T	0.8	0.2
T	F	0.9	0.1
T	T	0.99	0.01

3.5 Estimación en muestras grandes

- Teorema del Límite Central (CLT) y su papel en inferencia
- Estimación puntual: definiciones y ejemplos
- Estimación por intervalos: fórmula general y $Z_{\alpha/2}$
- Intervalos para la media (conocido y desconocido)
- Intervalos para una proporción
- Tamaño de muestra y margen de error
- Supuestos, interpretación y recomendaciones prácticas

Teorema del Límite Central (CLT)

- Si $X_1, \dots, X_n$ son i.i.d. con media μ y varianza finita σ^2 , entonces

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1) \quad (n \rightarrow \infty).$$

- Para n grande (regla práctica: $n \geq 30$), la distribución muestral de $\bar{X}$ se aproxima por

$$\bar{X} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

- **Definición:** un estimador puntual es un estadístico muestral que sirve como aproximación de un parámetro poblacional.
- **Ejemplos:**
 - Media poblacional μ estimada por la media muestral $\bar{X}$.
 - Proporción poblacional p estimada por la proporción muestral $\hat{p}$.
- **Propiedades deseables:** consistencia, sesgo pequeño (o nulo), varianza baja.

$$\text{Estimador} \pm Z_{\alpha/2} \times \text{Error estándar}$$

- $Z_{\alpha/2}$ es el cuantil de la normal estándar (ej.: $Z_{0,025} = 1,96$ para 95 %).
- El **error estándar** mide la variabilidad del estimador (depende de la muestra y del parámetro).

1. Intervalo de confianza para la media (conocido)

$$\bar{x} \pm Z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}} \right)$$

- $\bar{x}$: media muestral; σ : desviación estándar poblacional conocida.
- Ejemplo: $n = 100$, $\bar{x} = 50$, $\sigma = 10$, 95 % CI:

$$50 \pm 1,96 \left(\frac{10}{\sqrt{100}} \right) = 50 \pm 1,96$$

- Resultado: (48,04, 51,96).

1b. Intervalo de confianza para la media (desconocida, n grande)

$$\bar{x} \pm Z_{\alpha/2} \left(\frac{s}{\sqrt{n}} \right)$$

- Cuando σ es desconocida y n es grande, se reemplaza por s (desviación muestral) y se sigue usando Z .
- Para n pequeño (< 30) y σ desconocida, usar t_{n-1} en lugar de Z .

2. Intervalo de confianza para una proporción

$$\hat{p} \pm Z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

- $\hat{p}$ es la proporción muestral de éxitos.
- Condición práctica: $n\hat{p} \geq 5$ y $n(1 - \hat{p}) \geq 5$ para usar la aproximación normal.
- Ejemplo: $n = 400$, $\hat{p} = 0,2$, 95 % CI:

$$0,2 \pm 1,96 \sqrt{\frac{0,2 \cdot 0,8}{400}} = 0,2 \pm 0,0392$$

- Resultado: (0,1608, 0,2392).

Tamaño de muestra y margen de error

- Margen de error (ME) para la media:

$$ME = Z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \Rightarrow n = \left(\frac{Z_{\alpha/2} \sigma}{ME} \right)^2.$$

- Para proporciones (máxima varianza $\hat{p} = 0,5$):

$$n = \frac{Z_{\alpha/2}^2 0,25}{ME^2}.$$

- Use estimaciones previas de σ o $\hat{p}$ para calcular n .

Supuestos e interpretación

- **Supuestos:** muestras independientes; tamaño grande para aproximación normal; muestreo aleatorio representativo.
- **Interpretación del CI 95 %:** si repitiésemos el muestreo muchas veces, aproximadamente el 95 % de los intervalos construidos contendrían el verdadero parámetro.
- **No confundir:** el CI no dice que la probabilidad de que el parámetro esté en el intervalo sea 95 % en el sentido frecuentista; es una propiedad del procedimiento.

Recomendaciones prácticas

- Para $n \geq 30$ la aproximación normal suele ser adecuada; verificar con simulación si la distribución es muy sesgada.
- Para proporciones extremas o muestras pequeñas, usar métodos alternativos (Wilson, exacto).
- Siempre reportar: estimador puntual, intervalo con nivel de confianza, tamaño de muestra y supuestos.
- Complementar con análisis gráfico y, si procede, bootstrap para validar errores estándar.

Apéndice: valores críticos $Z_{\alpha/2}$

Nivel de confianza	$Z_{\alpha/2}$
90 %	1.645
95 %	1.960
99 %	2.576

3.6 Prueba de hipótesis — Planteamiento general

- **Hipótesis nula H_0 y alternativa H_1 .**
- **Estadístico de prueba T** calculado a partir de los datos.
- **p-valor:** probabilidad, bajo H_0 , de observar un valor tan extremo como el observado.
- **Decisión:** rechazar H_0 si $p < \alpha$.

Pruebas clásicas: t-test y Welch

- **t-test (igualdad de varianzas):** compara medias; usa t -student.
- **Welch:** no asume varianzas iguales; ajuste de grados de libertad.
- **Supuestos:** independencia, aproximación normal o n grande.

Prueba por permutación — Idea y procedimiento

- **Idea:** construir la distribución nula permutando etiquetas de grupo (intercambiabilidad).
- **Procedimiento:**
 - 1 Concatenar observaciones y permutar etiquetas manteniendo tamaños de grupo.
 - 2 Calcular $T^{(k)}$ para cada permutación.
 - 3 Estimar p -valor empírico: proporción de permutaciones con $T^{(k)}$ tan extremo como T_{obs} .
- **Ventaja:** no requiere normalidad ni igualdad de varianzas; exacta si se enumeran todas las permutaciones.

Cálculo del p-valor empírico

- **Unilateral izquierda:**

$$p = \frac{1}{K} \sum_{k=1}^K 1\{T^{(k)} \leq T_{\text{obs}}\}.$$

- **Unilateral derecha:**

$$p = \frac{1}{K} \sum_{k=1}^K 1\{T^{(k)} \geq T_{\text{obs}}\}.$$

- **Bilateral:**

$$p = \frac{1}{K} \sum_{k=1}^K 1\{|T^{(k)}| \geq |T_{\text{obs}}|\}.$$

- **Recomendación:** fijar la dirección antes de ver los datos.

Comparación t-test vs permutación

- **t-test:** rápido, basado en aproximaciones paramétricas; sensible a supuestos.
- **Permutación:** robusto frente a supuestos de forma; puede ser computacionalmente costoso.
- **Cuando usar permutación:** muestras pequeñas, distribuciones no normales, sospecha de heterocedasticidad.

Actividades prácticas con tu Colab

- Reproducir el ejemplo Predicate vs Next_Gen del cuaderno.
- Calcular p unilateral y bilateral; comparar con t-test y Welch.
- Repetir usando mediana en lugar de media; comparar robustez.
- Implementar versión vectorizada o paralela y comparar tiempos.

- **Resumen:** cubrimos distribución muestral, Bayes (teoría y método), redes bayesianas, estimación asintótica y pruebas (paramétricas y por permutación).
- **Recursos sugeridos:** apuntes de clase, cuaderno Colab (ya listo), lecturas sobre permutaciones y Bayes.
- **Siguiente paso:** ¿quieres que incluya notas del orador por diapositiva o ejemplos listos para copiar en Colab?

Apéndice: fórmulas clave

- Error estándar: $\text{se}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$.
- CLT: $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$.
- Bayes: $p(\theta | y) \propto p(y | \theta)p(\theta)$.
- Normalidad asintótica: $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} \mathcal{N}(0, V)$.