

Análisis de Series Temporales

Fundamentos, Modelos e Inferencia

Pastor E Pérez Estigarribia

June 9, 2026

Índice

- 1 Introducción y notación
- 2 Análisis exploratorio y estacionariedad
- 3 Formalización matemática
- 4 Modelos comunes e interpretación
- 5 Estimación y diagnóstico
- 6 Enfoque bayesiano
- 7 Interpretación y comunicación
- 8 Recursos y cierre

- Predicción y planificación: finanzas, demanda, capacidad en la nube.
- Detección de anomalías: SRE, IoT, mantenimiento predictivo.
- Comprender la dinámica temporal para tomar decisiones operativas.

- t : índice temporal (discreto), $t \in \mathbb{Z}$ o $\mathbb{N}$.
- X_t, Y_t : variables aleatorias en tiempo t .
- Espacio de estados: $\mathcal{X} \subseteq \mathbb{R}^d$, $\dim(\mathcal{X}) = d$.
- B (operador de retardo, lag): $BX_t = X_{t-1}$, $B^k X_t = X_{t-k}$.
- ε_t : innovación o ruido blanco, $\mathbb{E}[\varepsilon_t] = 0$, $\text{Var}(\varepsilon_t) = \sigma^2$.

- **Proceso estocástico:** ley generadora $\{X_t : t \in T\}$.
- **Realización:** la serie observada $(x_1, \dots, x_n) \in \mathcal{X}^n$.
- **Objetivo del análisis:** inferir propiedades del proceso a partir de la realización.


Exploración inicial (EDA)

- Visualizar la serie: tendencia, estacionalidad, rupturas (cambios repentinos que hacen que el patrón anterior deje de describir bien los datos).
- ACF (Función de Autocorrelación) y PACF (Función de Autocorrelación Parcial) : identificar memoria y órdenes candidatos.
- Periodograma / densidad espectral: identificar frecuencias dominantes. Detecta estacionalidad y ciclos (p. ej. picos en frecuencia anual o semanal)

Descomposición aditiva


$$Y_t = T_t + S_t + \varepsilon_t$$

- T_t : tendencia; S_t : estacionalidad; ε_t : residuo.
- Interpretación práctica: separar señal (T,S) del ruido para modelado.



Estacionariedad (WSS) — definición

- **WSS:** $\mu_t = \mu$ constante; $\text{Var}(X_t) = \sigma^2 < \infty$.
- $\gamma(t, s) = \gamma(h)$ con $h = s - t$ (autocovarianza depende solo del rezago).
- Consecuencias: ACF bien definida, espectro mediante transformada de Fourier.



Transformaciones para estacionarizar

- Diferenciación: $(1 - B)X_t = X_t - X_{t-1}$.
- Diferencia estacional: $(1 - B^m)X_t = X_t - X_{t-m}$, m Es la cantidad de estaciones o períodos (por ejemplo, $m = 12$ para datos mensuales, o $m = 4$ para datos trimestrales).
- Log, Box–Cox, detrending por promedios móviles o regresión.

Transformación logarítmica (Log)

- **Definición:** $Z_t = \log(Y_t)$ (usualmente log natural).
- **Efecto:** estabiliza varianza cuando la desviación crece proporcionalmente al nivel (efecto multiplicativo).
- **Interpretación:** diferencias en Z_t aproximan tasas de crecimiento: $\Delta \log Y_t \approx \% \Delta Y_t$.
- **Limitaciones:** requiere $Y_t > 0$; para ceros o valores negativos usar desplazamiento $Y_t + c$ con cuidado.

Transformación Box–Cox (familia paramétrica)

$$Y_t^{(\lambda)} = \begin{cases} \frac{Y_t^\lambda - 1}{\lambda}, & \lambda \neq 0, \\ \log(Y_t), & \lambda = 0. \end{cases}$$

- **Propósito:** encontrar λ que estabilice varianza y acerque normalidad.
- **Selección de λ :** por MLE (maximizar verosimilitud transformada) o por criterios de simetría/varianza.
- **Interpretación:** $\lambda = 1$ (sin transformación), $\lambda = 0$ (log), $\lambda = 0.5$ (raíz cuadrada).
- **Precaución:** requiere $Y_t > 0$; si hay ceros, usar desplazamiento mínimo justificado.

Detrending por promedios móviles (suavizado)

- **Idea:** estimar la tendencia local con una ventana centrada o causal:

$$\hat{T}_t = \frac{1}{2k+1} \sum_{j=-k}^k Y_{t+j} \quad \text{o} \quad \hat{T}_t = \frac{1}{m} \sum_{j=0}^{m-1} Y_{t-j}.$$

- **Detrended:** $Y_t - \hat{T}_t$ elimina fluctuaciones de baja frecuencia.
- **Ventajas:** simple, no paramétrico, útil para visualización y extracción rápida de tendencia.
- **Limitaciones:** borde de la serie (pérdida de observaciones), elección de ventana arbitraria, puede atenuar cambios bruscos.

Detrending por regresión (modelo paramétrico)

- **Modelo lineal de tendencia:**

$$Y_t = \beta_0 + \beta_1 t + \varepsilon_t.$$

Detrended: $Y_t - (\hat{\beta}_0 + \hat{\beta}_1 t)$.

- **Extensiones:** polinomios ($\beta_2 t^2$), funciones base (splines), indicadores de cambio de pendiente o puntos de quiebre.
- **Ventajas:** explícito, permite inferencia sobre la tendencia y pruebas formales; fácil incluir covariables y estacionalidad con dummies o Fourier.
- **Limitaciones:** riesgo de especificación errónea (p. ej. tendencia no lineal), sensibilidad a rupturas y outliers.

Comparación práctica: promedios móviles vs regresión

- **Promedios móviles:** no paramétrico, captura tendencia local; mejor para series con cambios suaves y sin estructura funcional conocida.
- **Regresión:** modela forma global de la tendencia; mejor cuando existe hipótesis sobre la forma (lineal, polinómica, puntos de cambio).
- **Estrategia combinada:** usar suavizado para exploración y regresión (o splines) para modelado y pronóstico.

Consideraciones prácticas y back-transformación

- **Back-transformar predicciones:** si modelos en escala transformada, convertir predicciones a la escala original requiere corregir sesgo (ej. para log: $\mathbb{E}[Y] \neq \exp(\mathbb{E}[\log Y])$; usar corrección por varianza o simulación).
- **Interpretabilidad:** transforma solo si mejora supuestos; documenta la razón y cómo interpretar coeficientes en la escala transformada.
- **Ceros y negativos:** antes de aplicar log/Box–Cox, justificar desplazamientos; preferir métodos robustos si hay muchos ceros.
- **Validación:** comparar modelos con y sin transformación mediante diagnóstico de residuos y pronóstico fuera de muestra.

$$\phi(B) = 1 - \phi_1 B - \cdots - \phi_p B^p, \quad \theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q.$$

Notación compacta para ARMA: $\phi(B)Y_t = \theta(B)\varepsilon_t$.

Modelos AR, MA y ARMA

- AR(p): $Y_t = \sum_{i=1}^p \phi_i Y_{t-i} + \varepsilon_t$. Autorregresivo (AR): Utiliza los valores pasados de la misma variable para predecir el futuro.
- MA(q): $Y_t = \mu + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t$. Media Móvil (MA): Utiliza los errores de pronósticos anteriores para ajustar y mejorar la predicción actual.
- ARMA(p,q): combinación de ambos.

ARIMA: Integrado (I), Aplica una "diferenciación" para estabilizar los datos y eliminar tendencias.

Teorema de Wold (resumen)

- Idea central (en una frase): cualquier serie temporal estacionaria se puede descomponer en una parte perfectamente predecible y una parte puramente aleatoria que se escribe como suma de choques pasados.
- Toda serie WSS se descompone en parte determinista η_t y parte indeterminista:

$$X_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \eta_t.$$

- Implicancia: la parte estocástica tiene representación $MA(\infty)$.

AR(1): interpretación detallada

$$Y_t = \phi Y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma_\varepsilon^2),$$

WN: white noise (ruido blanco)

- **Significado de ϕ :** mide la *persistencia* o memoria inmediata.
 - Si $|\phi|$ es cercano a 1, los efectos de un choque persisten mucho tiempo.
 - Si $|\phi|$ es cercano a 0, la serie olvida rápidamente los choques.
- **Condición de estacionariedad:** $|\phi| < 1$. Bajo esta condición la serie tiene media y varianza constantes en el tiempo.
- **Media:** si existe una media μ y no hay término constante, $\mathbb{E}[Y_t] = 0$.
Con constante c : $Y_t = c + \phi Y_{t-1} + \varepsilon_t \Rightarrow \mathbb{E}[Y_t] = \frac{c}{1 - \phi}$.

- **Interpretación operativa:** ϕ indica cuánto del valor pasado se transmite al presente; útil para entender persistencia de shocks (p. ej. demanda, latencia).
- **Estimación y verificación:**
 - Estimar ϕ por MLE o Yule–Walker.
 - Verificar $|\hat{\phi}| < 1$ para estacionariedad; comprobar ACF empírica decaída geométrica.
 - Diagnóstico: residuos deben comportarse como ruido blanco (test de Ljung–Box).
- **Señales de alerta:** $\hat{\phi}$ cercano a 1 sugiere raíz unitaria (posible no estacionariedad); $\hat{\phi} > 1$ indica explosión.

MA(q): interpretación

$$Y_t = \mu + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t.$$

- θ_j son pesos de respuesta a choques pasados (memoria de errores).
- MA tiene ACF truncada en q .

ARMA(p,q): interpretación práctica

- Combina memoria en valores (AR) y en shocks (MA).
- Útil cuando ACF y PACF muestran patrones mixtos.
- Representación $MA(\infty)$ si estacionario: $X_t = \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$.

ARIMA: integrar para no estacionariedad

$$\phi(B)(1 - B)^d Y_t = \theta(B)\varepsilon_t.$$

- d diferencias para remover tendencia estocástica.
- Selección de d mediante pruebas de raíz unitaria y diagnóstico.

$$x_{t+1} = F_t x_t + G_t \eta_t, \quad y_t = H_t x_t + \epsilon_t.$$

- Permiten modelar tendencia, estacionalidad y componentes latentes.
- Filtro de Kalman: solución óptima (MMSE) en caso lineal-gaussiano.

- MLE (máxima verosimilitud): estimadores eficientes asintóticamente.
- Método de momentos / Yule–Walker para AR: estimadores iniciales rápidos.
- Propiedades: consistencia, normalidad asintótica; usar información de Fisher para varianzas.

- Criterios: AIC, BIC para balance ajuste/complexidad.
- Tests de raíz unitaria: ADF, KPSS para decidir d .
- Diagnóstico de residuos: ACF de residuos, Ljung–Box, pruebas de normalidad y heterocedasticidad.

- Validación fuera de muestra: hold-out, rolling forecast.
- Métricas: RMSE, MAE, log score; para probabilístico: CRPS, interval coverage.
- Importancia de bandas predictivas y evaluación de calibración.

$$p(\theta \mid y) \propto p(y \mid \theta) p(\theta).$$

- Priors: incorporar conocimiento previo o regularizar parámetros.
- Posterior predictiva integra incertidumbre paramétrica y de ruido.

Priors típicos y su interpretación

- Priors normales débiles para coeficientes AR/MA.
- Priors Laplace para cambios escasos (sparse change points).
- Priors sobre varianza: Inverse-Gamma o Half-Cauchy para escala.

- MCMC (NUTS, HMC) para muestras del posterior; inferencia variacional (VI) para aproximaciones rápidas.
- Kalman filter / smoother: solución analítica para modelos lineales gaussianos (uso en Bayes como componente).
- Herramientas (mencionar sin código): PyMC, Stan, TensorFlow Probability, statsmodels (para diagnóstico clásico).

Ventajas y limitaciones del enfoque bayesiano

- **Ventajas:** incertidumbre completa, jerarquías, incorporación de conocimiento experto.
- **Limitaciones:** coste computacional, sensibilidad a priors mal especificados, necesidad de diagnóstico de convergencia.

Interpretación de parámetros

- ϕ_i : persistencia de la serie; cercanos a 1 indican memoria larga.
- θ_j : persistencia de choques; describen cómo errores pasados afectan el presente.
- ψ_j (MA(∞)): respuesta al impulso; útil para descomponer varianza por horizonte.

- Mostrar predicción puntual y bandas (percentiles).
- Explicar supuestos y limitaciones (estacionariedad, cambios de régimen).
- Presentar escenarios y decisiones operativas vinculadas a probabilidades.

- Box & Jenkins — *Time Series Analysis*.
- Durbin & Koopman — *Time Series Analysis by State Space Methods*.
- Documentación: statsmodels, PyMC, Stan, TensorFlow Probability.

Fin

Gracias